




# Тематическое моделирование LDA



Начало работы

# На этом уроке

- Модель LDA;
- Практика.



# Модель LDA

Более старый и популярный подход к регуляризации тематических моделей — модель LDA (латентное размещение Дирихле);

Для регуляризации использует априорное распределение Дирихле и параметры  $\Phi$  и  $\Theta$ ;

Предположи  $\alpha \in \mathbb{R}^{|T|}$  и  $\beta \in \mathbb{R}^{|W|}$  — векторы  $\phi_t$  и  $\theta_d$  генерируются их распределений Дирихле с параметрами



# Априорное распределение на параметры

Предположим, что вектор-столбцы  $\phi_t$  генерируются из распределения Дирихле с параметрами  $\beta \in \mathbb{R}^{|T|}$ :

$$\text{Dir}(\phi_t | \beta) = \frac{\Gamma(\beta_0)}{\prod_{w \in W} \Gamma(\beta_w)} \prod_{w \in W} \phi_{wt}^{\beta_w - 1}$$
$$\phi_{wt} > 0, \quad \beta_0 = \sum_{w \in W} \beta_w, \quad \beta_w > 0$$


Предположим, что вектор-столбцы  $\theta_d$  генерируются из распределения Дирихле с параметрами  $\alpha \in \mathbb{R}^{|W|}$ :

$$\text{Dir}(\theta_d | \alpha) = \frac{\Gamma(\alpha_0)}{\prod_{t \in T} \Gamma(\alpha_t)} \prod_{t \in T} \theta_{td}^{\alpha_t - 1}$$
$$\theta_{td} > 0, \quad \alpha_0 = \sum_{t \in T} \alpha_t, \quad \alpha_t > 0$$



# Почему именно распределение Дирихле

- Распределение Дирихле позволяет порождать разрежённые векторы;
- У него есть параметры, которые позволяют управлять степенью разрежённости;



- Оно является сопряжённым к мультиномиальному, что упрощает байесовский вывод в случае задачи тематического моделирования;
- Серьёзных лингвистических обоснований для использования распределения Дирихле нет.



# Обучение модели LDA

Обучать модель LDA можно разными способами:

- Вариационный вывод (Variational Bayes);
- Сэмплирование Гиббса (Gibbs Sampling);
- Максимум апостериорной вероятности (MAP).

VB и GS основываются на байесовском выводе. Используется сложный математический аппарат.

Параметры  $\Phi$  и  $\Theta$  не ищутся напрямую. Вместо этого строятся распределения на всевозможные значения параметров.

Это более сложная задача, которая в случае тематических моделей кажется избыточной. Итоговым результатом всё равно являются не сами распределения, а их точечные оценки.



# Обучение модели LDA

Обучать модель LDA можно разными способами:

- Вариационный вывод (Variational Bayes);
- Сэмплирование Гиббса (Gibbs Sampling);
- Максимум апостериорной вероятности (MAP).

MAP, как и метод максимального правдоподобия, строит точечную оценку параметров  $\Phi$  и  $\Theta$ .

Покажем, что этот подход приводит к модели, похожей на ARTM с регуляризатором сглаживания/разреживания.



# MAP для модели LDA

Применим к апостериорному распределению на параметры формулу Байеса:

$$p(\Phi, \Theta | D, \alpha, \beta) = \frac{p(D | \Phi, \Theta) p(\Phi, \Theta | \alpha, \beta)}{p(D | \alpha, \beta)} \propto p(D | \Phi, \Theta) p(\Phi, \Theta | \alpha, \beta)$$

Прологарифмируем результат и распишем:

$$\begin{aligned} \ln(p(D | \Phi, \Theta) p(\Phi, \Theta | \alpha, \beta)) &= \\ &= \ln \left( \prod_{i=1}^n p(d_i, w_i | \Phi, \Theta) p(\Phi | \beta) p(\Theta | \alpha) \right) = \\ &= \ln \left( \prod_{d \in D} \prod_{w \in d} p(d, w | \Phi, \Theta)^{n_{dw}} \prod_{t \in T} \text{Dir}(\phi_t | \beta) \prod_{d \in D} \text{Dir}(\theta_d | \alpha) \right) \end{aligned}$$





# MAP для модели LDA

Прологарифмируем результат и распишем:

$$\begin{aligned} \ln(p(D|\Phi, \Theta) p(\Phi, \Theta|\alpha, \beta)) &= \\ &= \ln\left(\prod_{d \in D} \prod_{w \in d} p(d, w|\Phi, \Theta)^{n_{dw}} \prod_{t \in T} \text{Dir}(\phi_t|\beta) \prod_{d \in D} \text{Dir}(\theta_d|\alpha)\right) = \\ &= \sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} + \left. \vphantom{\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td}} \right\} \text{Правдоподобие} \\ &\quad + \underbrace{\sum_{t \in T} \sum_{w \in W} \ln \phi_{wt}^{\beta_w - 1} + \sum_{d \in D} \sum_{t \in T} \ln \theta_{td}^{\alpha_t - 1}}_{\text{Регуляризатор}} \rightarrow \max_{\Phi, \Theta} \end{aligned}$$



# MAP для модели LDA

Регуляризатор априорного распределения Дирихле:

$$R(\Phi, \Theta) = \sum_{t \in T} \sum_{w \in W} (\beta_w - 1) \ln \phi_{wt} + \sum_{d \in D} \sum_{t \in T} (\alpha_t - 1) \ln \theta_{td}$$

Применим общую теорему ARTM и получим формулы М-шага EM-алгоритма:

$$\phi_{wt} = \text{norm}_{w \in W}(n_{wt} + \beta_w - 1)$$

$$\theta_{td} = \text{norm}_{t \in T}(n_{td} + \alpha_t - 1)$$

В зависимости от значений гиперпараметров происходит либо сглаживание ( $\alpha_t, \beta_w > 1$ ), либо разреживание ( $0 < \beta_w, \alpha_t < 1$ ).



# Модификации модели LDA

В научной литературе десятками описываются разные специализированные варианты LDA:

- Модели для классификации;
- Мультиязычные модели;
- Динамические модели;
- Иерархические модели.
- ...

Каждая обычно представляет собой базовую модель и некоторый регуляризатор для решения целевой задачи. Байесовский подход приводит к сложности комбинирования нескольких требований в одной модели. ARTM обходит это ограничение и позволяет собирать в одной модели любой число регуляризаторов без дополнительного математического вывода.



# ОСНОВНЫЕ ВЫВОДЫ

- Классическая математическая LDA вводит априорное распределение Дирихле на параметры модели;
- LDA можно обучать с помощью методов байесовского вывода и MAP;
- Байесовский вывод для тематических моделей оказывается достаточно трудоёмким и негибким;
- MAP строит точечные оценки параметров, как и метод максимума правдоподобия;
- MAP приводит к EM-алгоритму, похожему на ARTM с подходящим регуляризатором.

